

## Zadanie3

May 24, 2021

Wczytamy dane z pliku *zad3.csv*.

```
[1]: import pandas
data_frame = pandas.read_csv("zad3.csv")
data_frame
```

```
[1]:
```

	A	B	C	D
0	64	64.0	55.0	39.0
1	28	28.0	43.0	38.0
2	33	33.0	53.0	45.0
3	83	83.0	18.0	44.0
4	37	37.0	59.0	29.0
5	31	31.0	32.0	30.0
6	60	60.0	27.0	50.0
7	40	40.0	30.0	63.0
8	56	56.0	38.0	29.0
9	45	45.0	25.0	31.0
10	10	10.0	42.0	14.0
11	26	26.0	45.0	48.0
12	49	49.0	20.0	52.0
13	25	25.0	46.0	38.0
14	52	NaN	46.0	NaN
15	62	NaN	36.0	NaN
16	31	NaN	NaN	NaN
17	25	NaN	NaN	NaN

Jak widać, tym razem pracować będziemy z grupami, w których liczba próbek nie jest taka sama, dlatego zaczniemy od przekształcenia reprezentacji do wygodniejszej formy.

```
[2]: import numpy
data = {}

groups = data_frame.columns;

for group in data_frame.columns:
    data[group] = []
    for x in data_frame[group]:
        if not numpy.isnan(x):
```

```
data[group].append(x)
```

Przeprowadzimy analizę wariancji (ANOVA), w celu ustalenia czy **średnia liczba ogłoszeń w trzech gazetach jest taka sama**. Inaczej:

$$H_0 : x_{A\bullet} = x_{B\bullet} = x_{C\bullet} = x_{D\bullet}$$

$$H_a : \exists_{x_{i\bullet}, x_{j\bullet}, i \neq j} x_{i\bullet} \neq x_{j\bullet}$$

Wartości potrzebne do przeprowadzenia analizy można zaprezentować w postaci tabelki, w stosunku do pierwszego zadania zmieni się wzór na stopnie swobody, gdyż w każdej grupie jest ich inna liczba.

df	SS	MS	f	
$I - 1$	$SSA$	$MSA$	$\frac{MSA}{MSE}$	p-value
$\sum_{i=1}^I (J_i - 1)$	$SSE$	$MSE$		

gdzie  $I$  oznacza liczbę grup, a  $J_i$  obserwacji na  $i$ -tą grupę. Pierwszą i drugą kolumnę liczymy na podstawie danych, a każde kolejne na podstawie poprzednich.

Korzystając ze wzorów z wykładu, na początku ustalimy wartość zmienności międzygrupowej  $SSA$

$$SSA = \sum_{i=1}^I \sum_{j=1}^{J_i} (x_{i\bullet} - \bar{x})^2$$

gdzie

$$x_{i\bullet} = \frac{1}{J_i} \sum_{j=1}^{J_i} x_{ij},$$

$\bar{x}$  średnią wszystkich obserwacji, czyli

$$\bar{x} = \frac{1}{\sum_{i=1}^I J_i} \sum_{i,j} x_{ij}.$$

Najpierw policzymy wartości potrzebnych średnich  $x_{i\bullet}$  i  $\bar{x}$

```
[3]: from pprint import pprint
means = {}

for group in groups:
    means[group] = numpy.mean(data[group])

global_header = "global"
```

```
means[global_header] = numpy.mean(list(means.values()))

pprint(means)
```

```
{'A': 42.055555555555556,
 'B': 41.92857142857143,
 'C': 38.4375,
 'D': 39.285714285714285,
 'global': 40.426835317460316}
```

Po czym możemy przejść do wyznaczenia  $SSA$

```
[4]: ssa = 0
      for group in groups:
          ssa += len(data[group]) * (means[group] - means[global_header])**2

      print('SSA = ', ssa)
```

```
SSA = 160.871572927493
```

Z wykładu wiemy że z dokładnością do stałej

$$SSA \sim \chi^2(I - 1)$$

Teraz możemy przejść do wyznaczenia zmienności wewnątrzgrupowej  $SSE$

$$SSE = \sum_{i,j} (x_{ij} - x_{i\bullet})^2$$

```
[5]: sse = 0
      for group in groups:
          for x in data[group]:
              sse += (x - means[group])**2
      print("SSE = ", sse)
```

```
SSE = 14654.667658730157
```

Z wykładu wiemy, że

$$SSE \sim \chi^2 \left( \sum_{i=1}^I (J_i - 1) \right)$$

Następnie możemy przejść do wyznaczenia  $MSA$  i  $MSE$

$$MSA = \frac{SSA}{I - 1}$$

$$MSE = \frac{SSE}{\sum_{i=1}^I (J_i - 1)},$$

czyli odpowiednio  $SSA$  i  $SSE$  podzielone przez ich stopnie swobody.

```
[7]: deg_of_freedom_ssa = len(groups) - 1

deg_of_freedom_sse = 0
for group in groups:
    deg_of_freedom_sse += len(data[group]) - 1

msa = ssa / deg_of_freedom_ssa
mse = sse / deg_of_freedom_sse

print("MSA = ", msa)
print("MSE = ", mse)
```

```
MSA = 53.62385764249766
MSE = 252.66668377120962
```

Kolejnym krokiem jest wyznaczenia wartości  $F$

$$f = \frac{MSA}{MSE},$$

a stąd, że

$$MSA \sim \frac{\chi^2(I-1)}{I-1}$$

i

$$MSE \sim \frac{\chi^2\left(\sum_{i=1}^I (J_i - 1)\right)}{\sum_{i=1}^I (J_i - 1)}$$

wnioskujemy następujące (przy założeniu że  $H_0$  jest prawdziwe)

$$f = \frac{MSA}{MSE} \sim F\left(J-1, \sum_{i=1}^I (J_i - 1)\right),$$

bo rozkład Fishera-Snedecore'a może być przedstawiony jako stosunek przeskalowanych rozkładów  $\chi^2$ .

```
[8]: f = msa / mse
print("f = ", f)
```

```
f = 0.21223161218617256
```

Możemy teraz policzyć wartości krytyczne dla tego rozkładu i wybranego obszaru krytycznego. Sprawdźmy jak wyglądałby on dla  $\alpha = 0.1$

```
[9]: from scipy import stats

f_critical = stats.f.interval(0.9, deg_of_freedom_ssa, deg_of_freedom_sse)
print("Wartości skrajne: ", f_critical)
```

Wartości skrajne: (0.11663769974251183, 2.7635518374327885)

Wartość naszego wyliczonego  $f$  mieści się w tych przedziałach zatem nie ma powodu do odrzucenia hipotezy zerowej.